

TUGAS AKHIR BIG DATA DAN AI

Implementasi Big Data dan AI untuk Analisis Prediktif Data Kesehatan (Cardiovascular Disease)



FAKULTAS INFORMATIKA
INFORMATIKA
TELKOM UNIVERSITY

Tugas Besar: Artificial Intelligence dan Big Data

Implementasi Big Data dan AI untuk Analisis Prediktif Data Kesehatan (Cardiovascular Disease)

Fakultas Informatika – Informatika, Telkom University

Disusun Oleh:

Putu Satya Krisnaputra

Yoga Bayu Samudra

Nabil Falah Rabbani

Daftar Isi

1. Bab 1: Pendahuluan
 2. Bab 2: Landasan Teori dan Eksplorasi Data
 3. Bab 3: Metodologi Integrasi Big Data (PySpark)
 4. Bab 4: Pemodelan Artificial Intelligence (Random Forest)
 5. Bab 5: Analisis Hasil dan Visualisasi Pengetahuan
 6. Bab 6: Kesimpulan dan Saran
 7. Lampiran Kode Program
-

Bab 1: Pendahuluan

1.1 Latar Belakang Masalah

Penyakit kardiovaskular, yang mencakup gangguan pada jantung dan sistem pembuluh darah, kini menjadi salah satu ancaman kesehatan paling serius di tingkat global. Pertumbuhan pesat sistem informasi rumah sakit turut membawa dampak positif berupa tersedianya rekam medis pasien dalam jumlah yang luar biasa besar — inilah yang lazim disebut sebagai Big Data di bidang kesehatan. Data dalam skala tersebut menyimpan pola-pola tersembunyi yang berpotensi besar untuk dijadikan dasar deteksi dini risiko penyakit. Persoalannya, pendekatan statistik tradisional tidak mampu mengolah volume data seperti ini secara efisien. Di sinilah perpaduan antara teknologi pemrosesan Big Data dengan algoritma kecerdasan buatan (Artificial Intelligence) menjadi sangat relevan sebagai solusi yang komprehensif.

1.2 Tujuan dan Ruang Lingkup Proyek

Proyek ini dirancang untuk mensimulasikan penyelesaian masalah nyata di dunia kesehatan, dengan tiga sasaran utama:

- Memanfaatkan Apache Spark melalui antarmuka PySpark sebagai mesin pemrosesan data berskala besar secara terdistribusi.
 - Membangun model prediksi berbasis Random Forest Classifier guna mengidentifikasi probabilitas seorang pasien menderita penyakit kardiovaskular.
 - Menggali wawasan medis baru lewat analisis Feature Importance untuk mengetahui variabel biologis mana yang paling berpengaruh terhadap munculnya risiko penyakit tersebut.
-

Bab 2: Landasan Teori dan Eksplorasi Data

2.1 Deskripsi Dataset Big Data

Dataset yang dipakai dalam proyek ini adalah Cardiovascular Disease Dataset yang bersifat publik dan tidak mengandung informasi identitas pribadi pasien. Dataset ini terdiri dari 70.000 entri rekam medis, di mana setiap entri mewakili satu individu dengan total 13 atribut yang mencakup berbagai kondisi kesehatan. Dengan dimensi sebesar ini, dataset memenuhi kriteria yang ditetapkan untuk pengujian dan pemrosesan dalam konteks Big Data akademis.

2.2 Rincian Fitur Medis

Seluruh atribut dalam dataset dikelompokkan ke dalam empat kategori berikut:

1. **Fitur Faktual/Objektif:** Usia (Age), Tinggi Badan (Height), Berat Badan (Weight), dan Jenis Kelamin (Gender).
2. **Fitur Pemeriksaan Klinis:** Tekanan Darah Sistolik (ap_hi), Tekanan Darah Diastolik (ap_lo), Kadar Kolesterol (cholesterol), dan Kadar Glukosa (gluc).
3. **Fitur Perilaku Subjektif:** Kebiasaan Merokok (smoke), Konsumsi Alkohol (alco), dan Aktivitas Fisik (active).
4. **Variabel Target (Label):** cardio, yang merepresentasikan apakah pasien tersebut positif (1) atau negatif (0) terhadap risiko penyakit jantung.

Jumlah Data: 70000 baris

id	age	gender	height	weight	ap_hi	ap_lo	cholesterol	gluc	smoke	alco	active	cardio
0	18393	2	168	62.0	110	80	1	1	0	0	1	0
1	20228	1	156	85.0	140	90	3	1	0	0	1	1
2	18857	1	165	64.0	130	70	3	1	0	0	0	1
3	17623	2	169	82.0	150	100	1	1	0	0	1	1
4	17474	1	156	56.0	100	60	1	1	0	0	0	0

only showing top 5 rows

Bab 3: Metodologi Integrasi Big Data (PySpark)

3.1 Pemilihan Alat Pemrosesan (Apache Spark)

Mengingat volume data yang mencapai 70.000 baris — dan berpotensi jauh lebih besar dalam lingkungan produksi nyata — penggunaan library Python konvensional seperti Pandas akan sangat terbatas dari sisi kapasitas memori. Oleh karena itu, proyek ini memilih Apache Spark yang diakses melalui antarmuka PySpark. Spark unggul karena kemampuannya melakukan komputasi secara paralel di dalam memori (in-memory computing) pada arsitektur kluster, menjadikannya pilihan standar industri untuk pemrosesan data berskala masif.

3.2 Tahapan Preprocessing Data (Pembersihan & Transformasi)

Sebelum data rekam medis dapat diproses oleh model AI, diperlukan serangkaian tahapan pembersihan dan transformasi dalam lingkungan PySpark, meliputi:

- **Pembersihan Noise:** Kolom id dihilangkan karena hanya berfungsi sebagai penomor unik pasien dan tidak membawa informasi prediktif apapun bagi algoritma machine learning.
 - **Transformasi Vektorisasi:** Agar dapat dibaca oleh Spark MLlib, semua kolom fitur independen digabungkan menjadi satu kolom vektor tunggal bernama features menggunakan fungsi VectorAssembler.
 - **Splitting Data:** Data dibagi secara acak dengan rasio 80:20 — sebanyak 56.000 data untuk pelatihan dan 14.000 data untuk pengujian. Nilai seed=42 digunakan agar eksperimen dapat direproduksi secara konsisten.
-

Bab 4: Pemodelan Artificial Intelligence (Random Forest)

4.1 Justifikasi Pemilihan Random Forest Classifier

Untuk tugas prediksi pada dataset medis ini, dipilih algoritma Random Forest Classifier. Pemilihan ini didasarkan pada sejumlah keunggulan teknis yang relevan dengan karakteristik data kesehatan:

1. Ketahanan terhadap Outlier: Data rekam medis sering kali mengandung kesalahan input, seperti nilai tensi atau berat badan yang tidak wajar. Random Forest tidak rentan terhadap gangguan semacam ini karena keputusannya diambil secara kolektif dari ratusan pohon keputusan (dalam konfigurasi ini numTrees=100) melalui mekanisme majority voting.
2. Kemampuan Interpretasi (Explainability): Algoritma ini secara otomatis menghasilkan skor Feature Importances yang menunjukkan seberapa besar kontribusi masing-masing variabel dalam proses pengambilan keputusan model. Fitur ini sangat penting dalam konteks medis, di mana transparansi dan kemampuan menjelaskan keputusan AI merupakan syarat utama.

4.2 Proses Training dan Pengujian

Pelatihan model dilakukan secara paralel melalui infrastruktur Spark menggunakan 56.000 data latih. Setelah model selesai dibangun, kinerjanya diuji terhadap 14.000 data yang belum pernah dilihat sebelumnya. Evaluasi dilakukan dengan membandingkan label prediksi yang dihasilkan model dengan label asli pasien, menggunakan modul MulticlassClassificationEvaluator. Hasil pengujian menunjukkan akurasi sebesar 72,73%, yang merupakan nilai yang memadai untuk kasus klasifikasi data medis dengan variabel yang beragam.

```
▶ from pyspark.ml.classification import RandomForestClassifier
  from pyspark.ml.evaluation import MulticlassClassificationEvaluator

  # Bikin AI-nya
  rf = RandomForestClassifier(featuresCol='features', labelCol='cardio',

  print("Mulai training AI, tunggu bentar...")
  rf_model = rf.fit(train_data)

  # Test akurasi
  predictions = rf_model.transform(test_data)
  evaluator = MulticlassClassificationEvaluator(labelCol='cardio', predi
  accuracy = evaluator.evaluate(predictions)

  print(f"Akurasi Model Random Forest: {accuracy * 100:.2f}%")

... Mulai training AI, tunggu bentar...
  Akurasi Model Random Forest: 72.73%
```

Bab 5: Analisis Hasil dan Visualisasi Pengetahuan

5.1 Interpretasi Hasil Melalui Visualisasi Matplotlib

Salah satu tujuan inti dari proyek Big Data ini adalah mengubah sekumpulan data mentah menjadi pengetahuan yang dapat langsung dimanfaatkan oleh para pengambil keputusan. Untuk itu, skor bobot kepentingan tiap fitur yang dihasilkan oleh model PySpark diekstraksi dan divisualisasikan dalam bentuk grafik batang horizontal menggunakan Matplotlib. Grafik ini menyajikan urutan fitur medis berdasarkan tingkat kontribusinya terhadap prediksi risiko penyakit kardiovaskular.



```

import pandas as pd
import matplotlib.pyplot as plt

# Ambil data faktor apa yang paling bikin sakit jantung
importances = rf_model.featureImportances.toArray()
feature_imp_df = pd.DataFrame({
    'Fitur': feature_columns,
    'Pentingnya_Fitur': importances
}).sort_values(by='Pentingnya_Fitur', ascending=False)

# Bikin gambarnya
plt.figure(figsize=(10, 6))
plt.barh(feature_imp_df['Fitur'], feature_imp_df['Pentingnya_Fitur'],
plt.gca().invert_yaxis()
plt.title('Faktor Paling Berpengaruh Terhadap Penyakit Jantung (Random
plt.xlabel('Tingkat Kepentingan')
plt.ylabel('Fitur Medis')
plt.grid(axis='x', linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()

```



5.2 Bedah Analitik dan Penemuan Pengetahuan (Knowledge Discovery)

Berdasarkan visualisasi AI di atas, dapat ditarik wawasan medis baru terhadap 70.000 pasien:

- **Faktor Fatal (Sangat Dominan):** Tekanan darah adalah indikator paling mutlak. **Tekanan Darah Sistolik (ap_hi)** dan **Tekanan Darah Diastolik (ap_lo)** menguasai porsi pembobotan algoritma secara mayoritas. Pasien dengan nilai ekstrem pada dua kolom ini memiliki probabilitas tertinggi terdiagnosa penyakit jantung.
- **Faktor Biologis Menengah:** Usia pasien (Age), metrik Kolesterol (Cholesterol), dan Berat Badan (Weight) muncul di urutan berikutnya. Hal ini sangat logis secara medis, bahwa plak kolesterol yang bertumpuk seiring bertambahnya usia akan memperberat kerja jantung.
- **Faktor Gaya Hidup (Sangat Lemah):** Fakta mengejutkan dari dataset Big Data ini adalah variabel konsumsi alkohol (alco), rokok (smoke), dan olahraga (active) hanya memberikan sumbangsih bobot prediktif yang amat sangat kecil pada AI. Ini mengindikasikan bahwa meski gaya hidup itu penting, jika genetika tensi darah pasien sudah rusak, maka risiko gagal jantung akan tetap sangat tinggi terlepas dari kebiasaan merokoknya.

Bab 6: Kesimpulan dan Saran

6.1 Kesimpulan

Implementasi teknologi Artificial Intelligence dalam ekosistem Big Data telah dieksekusi dengan sukses. Penggunaan Apache Spark membuktikan bahwa komputasi data puluhan ribu baris dapat berjalan sangat mulus dan tahan terhadap *bottleneck* memori. Algoritma Random Forest berhasil bukan hanya menebak pasien berisiko dengan akurasi yang memuaskan, melainkan juga menelanjangi pola tersembunyi yang membuktikan bahwa kendali tekanan darah jauh lebih mendesak ditangani secara klinis dibandingkan sekadar intervensi gaya hidup konvensional.

6.2 Saran Implementasi Nyata

Sebagai implikasi dunia nyata, rumah sakit atau fasilitas kesehatan dapat mengintegrasikan arsitektur kode ini ke dalam sistem *Electronic Health Record* (EHR) mereka. Setiap kali perawat memasukkan data pengukuran tensi darah yang baru, sistem secara otomatis (melalui *stream* Spark) akan membunyikan alarm peringatan jika pasien tersebut memiliki kombinasi tensi dan usia yang masuk ke dalam *threshold* bahaya model Random Forest ini.

Lampiran: Dokumentasi Kode Program (Link)

Tautan Kode Program (Google Colab / Google Drive):

[INSTRUKSI UNTUK KRISNA: HAPUS TEKS INI LALU PASTE LINK GOOGLE DRIVE TEMPAT KAMU MENGUPLOAD FILE .IPYNB-NYA DI SINI. Pastikan link-nya sudah disetting "Anyone with the link can view".]